# Matching Networks for One Shot Learning

Author: Vinyals et al., 2016

21. 06.03 신한이

목차

Abstract

Introduction

Related Works

- Method
  - Model Architecture
  - Training Strategy
- Experiments

#### **Abstract**

- 비전과 자연어 부문 연구에서 빠른 발전이 이루어짐.
- 하지만,
- ⇒ Standard supervised deep learning 분야에서 <u>적은 데이터</u>를 통해 새로운 컨셉을 학습하는 데에 <u>만족스러운 솔루션</u>이 없음.
- ⇒ 여전히 많은 데이터를 필요로 함
- 이를 해결하기 위해,
- ⇒ **External memory**를 추가한 NN 구조 도입
- ⇒ Small labelled support set만으로도 learning이 가능하다.

### **Related Works**

#### **Metric-Learning**

**Matching Network** 

**Prototypical Network** 

**Relation Network** 

Embedding function 과 Distance 에 따라 달라짐.

- **Distance** : 임베딩 공간에서의 데 이터 간 거리
- Embedding func. : 데이터를 저차 원으로 임베딩

### Introduction

### **Matching Network**

Matching Network 에서는

<u>convolution과 Istm 기반 embedding function</u>과 <u>cosine similarity distance</u>를 사용했고

Meta-train set에서 **task sampling**을 통해 support, query set을 뽑은 후 query set을 잘 분류하기 위한 episode training을 통해 모델을 학습

### Introduction

### **Few Shot Learning**


#### [ Few Shot Learning ]

: 소수 데이터(support data) 로 다수 데이터(query data)를 예측해야 하는 과업에 적용되는 학습 기법

#### [ One Shot Learning ]

: which consists of learning a class from a single labelled example.

## Introduction



#### Method


[from Paper]

Our non-parametric approach to solving one-shot learning is based on **two components**.

**First,** our model architecture follows recent advances in neural networks (1)augmented with memory (as discussed in Section 3).

**Second**, we employ a <u>(2)training strategy</u> which is tailored for one-shot learning from the support set S.

Model Architecture : External memory 를 추가한 NN 구조 (cf. seq2seq, pointer NN)



The Attention Kernel : a(^x, xi)를 정의

#### C: cosine distance

$$a(\hat{x},x_i) = e^{c[f(\hat{x}),g(x_i))}/\sum_{j=1}^k e^{c[f(\hat{x}),g(x_j))}$$
 f(x), g(x): embedding func.

Full Context Embeddings : ^x를 임베딩하는 f도 S를 고려할 수 있다.

$$f(\hat{x}, S) = \text{attLSTM}(f'(\hat{x}), g(S), K)$$

- LSTM 구조를 사용
- 매 time step마다 같은 f값을 넣어준다.

### Method

#### Training Strategy

#### Objective function 최대화

$$\theta = \arg \max_{\theta} E_{L \sim T} \left[ E_{S \sim L, B \sim L} \left[ \sum_{(x,y) \in B} \log P_{\theta} \left( y | x, S \right) \right] \right].$$

- 1) L을 T로부터 샘플링한다.
- 2) L을 이용해 support set S와 batch B를 샘플링한다.
- 3) Support set S를 이용해 B의 샘플에 대해 label을 예측한다.

# **Experiments**

Model	Matching Fn	Fine Tune	5-way Acc 1-shot 5-shot	20-way Acc 1-shot 5-shot
PIXELS	Cosine	N	41.7% 63.2%	26.7% 42.6%
BASELINE CLASSIFIER	Cosine	N	80.0% 95.0%	69.5% 89.1%
BASELINE CLASSIFIER	Cosine	Y	82.3% 98.4%	70.6% 92.0%
BASELINE CLASSIFIER	Softmax	Y	86.0% 97.6%	72.9% 92.3%
MANN (No Conv) [21]	Cosine	N	82.8% 94.9%	
CONVOLUTIONAL SIAMESE NET [11]	Cosine	N	96.7% 98.4%	88.0% 96.5%
CONVOLUTIONAL SIAMESE NET [11]	Cosine	Y	97.3% 98.4%	88.1% 97.0%
MATCHING NETS (OURS)	Cosine	N	98.1% 98.9%	<b>93.8%</b> 98.5%
MATCHING NETS (OURS)	Cosine	Y	97.9% 98.7%	93.5% <b>98.7</b> %

Table 1: Results on the Omniglot dataset.

=> 모두 N-way k-shot learning 작업

### Conclusion

( \* Metric-based approach의 )

### 장점

- Metric 기반의 Meta learning은 단순하고 직관적이며, Embedding 의 시각화와 해석하기에 쉽다

### 단점

- domain adaptation에 약하다.
  ( = domain간 차이가 큰 경우 adaptation이 어렵다. )
- 계산량이 많다.

# 참조 자료

+ Paper

https://arxiv.org/pdf/1606.04080.pdf

- Refer

https://jiminsun.github.io/2019-02-20/Vinyals-2016/

- Refer

http://www.navisphere.net/6014/matching-networks-for-one-shot-learning/